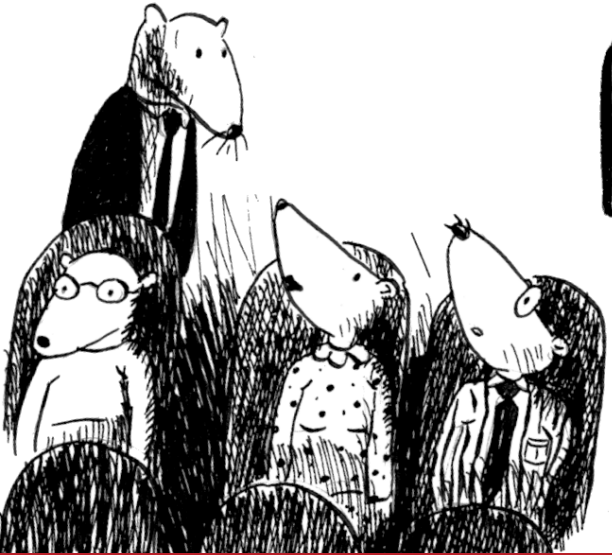


Aula 02
Machine Learning

Análise e Desenvolvimento de Sistemas

Eduardo Camargo de Siqueira

INSTITUTO FEDERAL
Brasília



drawn by adit.io

Este material foi criado por Eduardo Camargo de Siqueira e está disponível livremente para uso não comercial. Se você usar alguma parte deste material, adicione "copyright duca.pro".

Se você encontrar algum erro ou tiver alguma dúvida, envie um e-mail: eduardo.siqueira@ifb.edu.br. Obrigado por contribuir e espero que você aprenda bastante com este material!

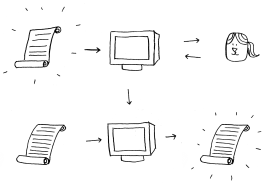
INSTITUTO FEDERAL
Brasília

Machine Learning

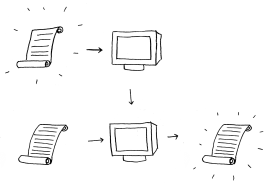
- Campo da Inteligência Artificial que permite que computadores aprendam padrões a partir de dados.
- Utiliza algoritmos para realizar previsões ou tomar decisões sem programação explícita.
- Aplicado em diversas áreas, como reconhecimento de imagem, análise preditiva e assistentes virtuais.

INSTITUTO FEDERAL
Brasília

Machine Learning



Aprendizado supervisionado - drawn by adit.io



Aprendizado não-supervisionado - drawn by adit.io

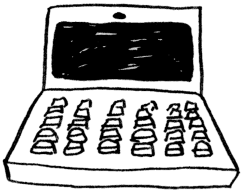


Aprendizado por reforço - drawn by adit.io

INSTITUTO FEDERAL
Brasília

Ferramentas

- Scikit-learn: Modelos clássicos de Machine Learning.
- TensorFlow e PyTorch: Deep Learning e Redes Neurais.
- Hugging Face: Modelos de NLP pré-treinados.



drawn by adit.io

INSTITUTO FEDERAL
Brasília

Machine Learning

- Qualidade dos dados influencia diretamente o desempenho.
- Overfitting: Modelo aprende padrões específicos demais do conjunto de treino.
- Explicabilidade dos modelos: Como garantir que as previsões sejam confiáveis?

INSTITUTO FEDERAL
Brasília

Modelos supervisionados

Regressão linear

- Algoritmo supervisionado usado para prever valores contínuos.
- Modelo matemático: $Y = aX + b$.
- Aplicações: Previsão de preços, crescimento populacional, análise de tendências.

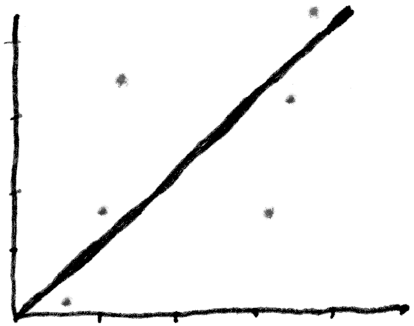
INSTITUTO FEDERAL
Brasília

Regressão linear

- Estabelece uma relação entre variável independente (X) e dependente (Y).
- Minimiza o erro entre a linha de regressão e os pontos de dados usando o método dos mínimos quadrados.
- Pode ser simples (uma variável independente) ou múltipla (mais de uma variável independente).

INSTITUTO FEDERAL
Brasília

Regressão linear



Exemplo em Python

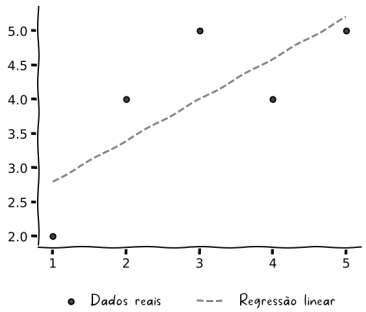
```python
import numpy as np
import matplotlib.pyplot as plt
from sklearn.linear_model import
      LinearRegression

# Dados de exemplo
X = np.array([1, 2, 3, 4, 5]).reshape(-1, 1)
Y = np.array([2, 4, 5, 4, 5])

# Criando e treinando o modelo
modelo = LinearRegression()
modelo.fit(X, Y)

# Fazendo previsões
Y_pred = modelo.predict(X)

# Visualizando os resultados
plt.scatter(X, Y, color='blue', label='Dados
       Reais')
plt.plot(X, Y_pred, color='red', label='
      Regressão Linear')
plt.legend()
plt.show()
```



Regressão logística

- Algoritmo de aprendizado supervisionado usado para resolver problemas de classificação binária.
- Diferente da regressão linear, que prevê valores contínuos, a regressão logística prevê probabilidades associadas a cada classe.

INSTITUTO FEDERAL
Brasília

Função sigmoide

- A regressão logística usa a **função sigmoide**:

$$\sigma(z) = \frac{1}{1 + \exp(-1)}$$

  Onde: $z = w_0 + w_1 x_1 + w_2 x_2 + \cdots + w_n x_n$ é a combinação linear das variáveis de entrada.

- $\sigma(z)$ transforma o valor para um intervalo entre 0 e 1, interpretado como uma probabilidade.
- Se $\sigma(z) \geq 0.5$, classificamos como 1; caso contrário, classificamos como 0.

INSTITUTO FEDERAL
Brasília

Exemplo

Dado um conjunto de dados de pacientes com informações sobre pressão arterial e colesterol, queremos prever se um paciente tem risco alto de doença cardíaca (1) ou risco baixo (0).

INSTITUTO FEDERAL
Brasília

Implementação em Python

Importação das bibliotecas

```python
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.model_selection import
      train_test_split
from sklearn.preprocessing import
      StandardScaler
from sklearn.linear_model import
      LogisticRegression
from sklearn.metrics import accuracy_score,
      classification_report,
      confusion_matrix
```

Geração de dados sintéticos

```python
from sklearn.datasets import
      make_classification

# Criar dados fictícios para classificação
      binária
X, y = make_classification(n_samples=1000,
      n_features=2, n_classes=2,
                           n_informative=2,
       n_redundant=0, n_repeated=0,
      random_state=42)

# Convertendo para DataFrame
df = pd.DataFrame(X, columns=['
      Pressão_Arterial', 'Colesterol'])
df['Risco_Alto'] = y

# Visualizar amostra dos dados
print(df.head())
```

INSTITUTO FEDERAL
Brasília

Implementação em Python

Divisão de dados de treino e teste

```
1 X_train, X_test, y_train, y_test =
      train_test_split(X, y, test_size=0.2,
      random_state=42)
2
3 # Padronização dos dados para melhor
      desempenho do modelo
4 scaler = StandardScaler()
5 X_train = scaler.fit_transform(X_train)
6 X_test = scaler.transform(X_test)
```

Treinamento do modelo

```
1 # Criando e treinando o modelo de regressão
      logística
2 modelo = LogisticRegression()
3 modelo.fit(X_train, y_train)
```

INSTITUTO FEDERAL
Brasília

Implementação em Python

Avaliação do modelo

```python
# Predições
y_pred = modelo.predict(X_test)

# Acurácia
acc = accuracy_score(y_test, y_pred)
print(f'Acurácia do Modelo: {acc:.2f}')

# Relatório de classificação
print("Relatório de Classificação:")
print(classification_report(y_test, y_pred))

# Matriz de confusão
cm = confusion_matrix(y_test, y_pred)
sns.heatmap(cm, annot=True, fmt='d', cmap='Blues')
plt.xlabel("Predito")
plt.ylabel("Real")
plt.show()
```

INSTITUTO FEDERAL
Brasília

Interpretação dos resultados

- Verdadeiros Positivos (TP): Casos corretamente classificados como risco alto.
- Falsos Positivos (FP): Casos classificados erroneamente como risco alto.
- Falsos Negativos (FN): Casos de risco alto classificados como risco baixo.
- Verdadeiros Negativos (TN): Casos corretamente classificados como risco baixo.



drawn by adit.io

INSTITUTO FEDERAL
Brasília

Métricas

- Precisão:

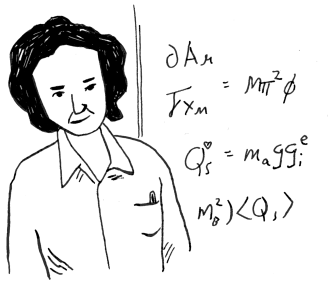
$$\text{precision} = \frac{TP}{TP + FP}$$

- Recall:

$$\text{recall} = \frac{TP}{TP + FN}$$

- F1-score (média harmônica):

$$\text{f1score} = 2 \times \frac{\text{precision} \times \text{recall}}{\text{precision} + \text{recall}}$$

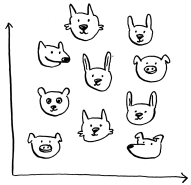


INSTITUTO FEDERAL
Brasília

Atividade

Adapte o código para usar um dataset real disponível no Kaggle para classificação binária.

Clique aqui



INSTITUTO FEDERAL
Brasília

Naïve Bayes

- Algoritmo de classificação baseado no Teorema de Bayes, assumindo que os atributos são independentes entre si.
- Amplamente utilizado para classificação de textos, detecção de spam, análise de sentimentos, entre outros.

INSTITUTO FEDERAL
Brasília

Implementação em Python

Importação da biblioteca

```
1 from sklearn.naive_bayes import GaussianNB
```

Treinamento do modelo

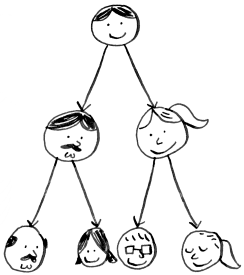
```
1 # Criando e treinando o modelo de Naïve Bayes Gaussiano
2 modelo = GaussianNB()
3 modelo.fit(X_train, y_train)
```

INSTITUTO FEDERAL
Brasília

Árvores de decisão

Árvores de decisão

- Modelos de aprendizado supervisionado usados para tarefas de classificação e regressão.
- São intuitivas, interpretáveis e poderosas, sendo amplamente utilizadas em problemas de tomada de decisão.
- A ideia principal é dividir os dados de forma recursiva, criando regras de decisão baseadas nas variáveis preditoras.



drawn by adit.io

INSTITUTO FEDERAL
Brasília

Árvores de decisão

Vantagens

- Fácil interpretação;
- Requer pouca preparação dos dados;
- Funciona para dados numéricos e categóricos.

Desvantagens

- Propensa a overfitting (se não limitada);
- Sensível a pequenas variações nos dados.

INSTITUTO FEDERAL
Brasília

Implementação em Python

Importação da biblioteca

```
from sklearn.tree import DecisionTreeClassifier, plot_tree
```

Treinamento do modelo

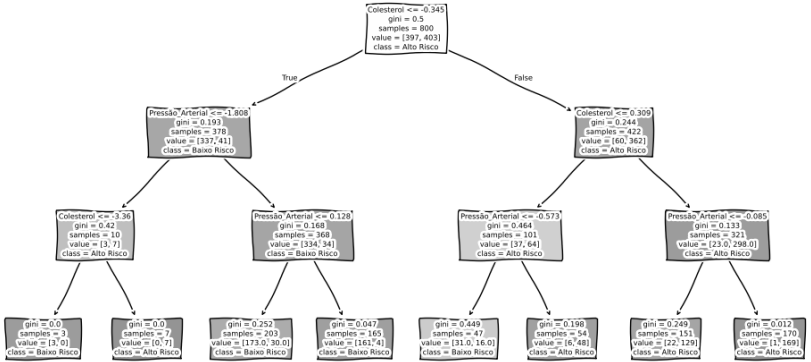
```
# Criando e treinando o modelo de árvore de decisão
modelo = DecisionTreeClassifier(criterion='gini', max_depth=3, random_state=42)
modelo.fit(X_train, y_train)
```

Visualização da árvore

```
plt.figure(figsize=(12,6))
plot_tree(modelo, feature_names=['Pressão_Arterial', 'Colesterol'], class_names=['Baixo
      Risco', 'Alto Risco'], filled=True)
plt.show()
```

INSTITUTO FEDERAL
Brasília

Visualização da árvore



INSTITUTO FEDERAL
Brasília

Random Forest

- Algoritmo de aprendizado supervisionado baseado em múltiplas árvores de decisão.
- Combina diversas árvores para obter um modelo mais preciso, robusto e resistente a overfitting.
- Cada árvore toma uma decisão independentemente.
  - No caso de classificação: a classe final é determinada por votação da maioria.
  - No caso de regressão: a previsão final é a média das previsões das árvores.



drawn by adit.io

INSTITUTO FEDERAL
Brasília

Implementação em Python

Importação da biblioteca

```
1 from sklearn.ensemble import RandomForestClassifier
```

Treinamento do modelo

```
1 # Criando e treinando o modelo Random Forest
2 modelo = RandomForestClassifier(n_estimators=100, max_depth=5, random_state=42)
3 modelo.fit(X_train, y_train)
```

INSTITUTO FEDERAL
Brasília

Support Vector Machine (SVM)

Support Vector Machine

- Algoritmo de aprendizado de máquina supervisionado usado para classificação e regressão.
- Amplamente utilizado devido à sua alta precisão e capacidade de generalização.
- O principal conceito é encontrar um hiperplano ótimo que separa os dados de diferentes classes no espaço de entrada.

INSTITUTO FEDERAL
Brasília

Support Vector Machine

- Algoritmo de aprendizado de máquina supervisionado usado para classificação e regressão.
- Amplamente utilizado devido à sua alta precisão e capacidade de generalização.
- O principal conceito é encontrar um hiperplano ótimo que separa os dados de diferentes classes no espaço de entrada.

INSTITUTO FEDERAL
Brasília

Tipos de SVM

- Linear: Usado quando os dados podem ser separados por uma reta.
- Não-linear: Utiliza funções kernel para transformar os dados em um espaço de maior dimensão, onde podem ser separados linearmente.

INSTITUTO FEDERAL
Brasília

Implementação em Python

Importação da biblioteca

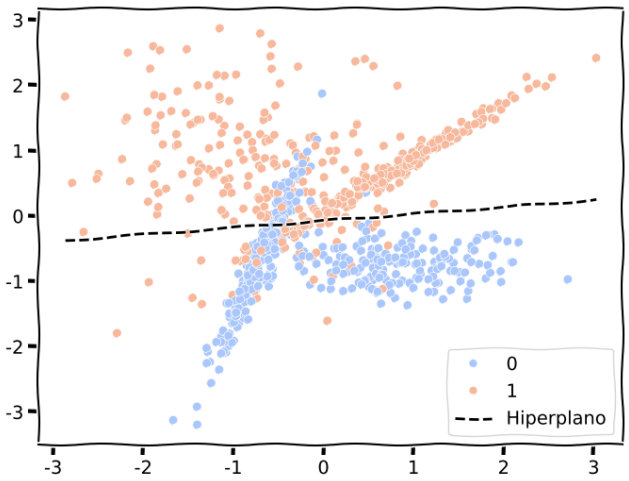
```
1 from sklearn.svm import SVC
```

Treinamento do modelo

```
1 # Criando e treinando um modelo SVM com kernel linear
2 modelo = SVC(kernel='linear', C=1.0)
3 modelo.fit(X_train, y_train)
```

INSTITUTO FEDERAL
Brasília

Visualização do hiperplano



INSTITUTO FEDERAL
Brasília

Atividade

Adapte os códigos para usar o dataset 'Predição de Insuficiência Cardíaca', disponibilizado no Kaggle. Qual foi o melhor resultado?

INSTITUTO FEDERAL
Brasília

"Compreender o mundo envolve encontrar padrões nos dados"

- Geoffrey Hinton



drawn by adit.io

INSTITUTO FEDERAL
Brasília

FIM

- Dúvidas!?
- E-mail: eduardo.siqueira@ifb.edu.br / luiz.morais@ifb.edu.br
- http://duca.pro.br/
- Ilustrações: copyright Manning Publications, drawn by adit.io
- Obrigado pela atenção!

INSTITUTO FEDERAL
Brasília